

Memoria Técnica del Proyecto

<u>Nombre del Proyecto:</u>	R2-D-Data
<u>Autores:</u>	Fernando Beneytez Maesa Pablo de Aguinaga Cabredo Marcela Motta Mario Pérez Ramos Álvaro Ruiz Vázquez Gabriela Schneider Vannoni
Fecha:	3 de marzo a 3 de abril de 2025
Bootcamp:	Big Data, IA & Machine Learning, XIV edición.

INDICE

1. RESUMEN.....	2
2. INTRODUCCIÓN.....	3
3. DESCRIPCION DEL PROBLEMA Y MOTIVACIÓN.....	3
4. OBJETIVOS DEL PROYECTO.....	4
5. METODOLOGÍA.....	5
5.1. DESCRIPCION DE LOS DATASET DE SWELL-KW.....	5
5.2. PROCESO DE ETL Y LIMPIEZA DE DATOS.....	6
5.3. ANÁLISIS EXPLORATORIO DE DATOS (EDA).....	6
5.4. PREPROCESAMIENTO DE DATOS.....	6
5.5. EXTRACCIÓN Y SELECCIÓN DE CARACTERISTICAS.....	7
6. MODELADO Y EVALUACIÓN.....	8
6.1. MODELOS IMPLEMENTADOS.....	8
6.2. METRICAS DE EVALUACION.....	8
6.3. RESULTADOS OBTENIDOS.....	9
7. DESPLIEGUE DEL SISTEMA.....	10
7.1. FASTAPI.....	10
7.2. ARQUITECTURA DEL SISTEMA EN GOOGLE CLOUD PLATFORM (GCP).....	11
8. VISUALIZACIÓN DE RESULTADOS EN POWER BI.....	12
8.1. ANÁLISIS GENERAL POR CONDICIÓN E INDICADORES.....	12
8.2. ESTADO EMOCIONAL POR CATEGORÍAS DE ESTRÉS.....	12
8.3. COMPARATIVA DE MODELOS PREDICTIVOS.....	12
8.4. CONCLUSIONES DEL ANÁLISIS:.....	12
9. CONCLUSIONES Y TRABAJO FUTURO.....	13
10. BIBLIOGRAFÍA O REFERENCIAS.....	13
11. ANEXOS.....	14
11.1. NOTEBOOKS DE ANALISIS Y PROCESAMIENTO.....	14
11.2. VISUALIZACIONES EN POWER BI.....	14
11.3. ENLACES COMPLEMENTARIOS.....	14

1. RESUMEN

Este proyecto explora la predicción automática del nivel de estrés y estado emocional de personas durante la realización de tareas laborales, empleando técnicas de Machine Learning y Deep Learning. El sistema desarrollado busca ofrecer apoyo en la evaluación del comportamiento bajo presión, lo cual podría resultar útil, por ejemplo, en procesos de selección de personal o análisis de desempeño.

Se ha utilizado el conjunto de datos SWELL-KW, que recoge información fisiológica, conductual y subjetiva de 25 participantes sometidos a escenarios de estrés inducido. Este dataset multimodal proporciona registros como expresiones faciales, postura corporal, señales biométricas y actividad informática.

El proceso ha incluido desde la integración y transformación de los datos hasta el desarrollo de modelos predictivos (XGBoost, redes neuronales, regresión logística...) y la visualización de resultados. La predicción del estrés se realiza en una escala cualitativa de cuatro niveles (de “demasiado relajado” a “estrés alto”), permitiendo representar su evolución a lo largo del tiempo de forma clara y precisa. Todo el desarrollo se ha realizado mayoritariamente en Python y se ha complementado con herramientas como Power BI y Google Cloud.

2. INTRODUCCIÓN

El impacto del estrés en el entorno laboral es un tema cada vez más estudiado debido a sus consecuencias en la salud mental, la productividad y la toma de decisiones. En los últimos años, el avance de tecnologías como el aprendizaje automático ha abierto nuevas posibilidades para analizar estados emocionales de forma objetiva y automatizada.

Este proyecto se enmarca en ese contexto, explorando cómo los modelos de Machine Learning y Deep Learning pueden aplicarse a datos multimodales —como señales fisiológicas, posturas, expresiones faciales o actividad informática— con el fin de detectar y clasificar el nivel de estrés experimentado por una persona en situaciones de trabajo simuladas.

El desarrollo de este tipo de soluciones tiene múltiples aplicaciones potenciales, desde la mejora de la experiencia de usuario en entornos digitales hasta la toma de decisiones en recursos humanos, ergonomía o salud ocupacional.

3. DESCRIPCION DEL PROBLEMA Y MOTIVACIÓN

En el contexto laboral actual, el estrés y la gestión emocional son factores cada vez más relevantes para la productividad, el bienestar y la toma de decisiones en las organizaciones. La presión por alcanzar objetivos, los entornos cambiantes y las exigencias cognitivas propias

de los trabajos del conocimiento pueden provocar un impacto significativo en el estado emocional de las personas.

Sin embargo, la evaluación del estrés y del estado emocional suele depender de instrumentos subjetivos como encuestas o autoevaluaciones, que no siempre reflejan con precisión el estado real del individuo. Esto plantea la necesidad de sistemas objetivos y automatizados que permitan medir estos indicadores de forma fiable y en tiempo real.

Este proyecto nace de esa necesidad: desarrollar un sistema que, a partir de señales fisiológicas, expresiones faciales, postura corporal y patrones de interacción con el ordenador, sea capaz de estimar el nivel de estrés de un individuo. El objetivo no es solo avanzar en la investigación sobre modelado emocional, sino también explorar su aplicación práctica, por ejemplo, en procesos de selección, ergonomía digital o diseño de entornos de trabajo más saludables.

La motivación adicional es el reto técnico y formativo que implica combinar múltiples fuentes de datos, aplicar técnicas de Machine Learning/Deep Learning, y construir una solución integral aplicable en un entorno real.

4. OBJETIVOS DEL PROYECTO

Este proyecto tiene como meta la creación de un sistema automatizado para el análisis del estrés mediante datos multimodales. Para ello, se han definido los siguientes objetivos concretos:

- **Recopilar, integrar y transformar datos multimodales** (expresiones faciales, postura, actividad informática y señales fisiológicas) del dataset SWELL-KW.
- **Aplicar un proceso completo de análisis de datos**, que incluya limpieza, preprocesamiento, análisis exploratorio y selección de características relevantes.
- **Desarrollar y comparar varios modelos de predicción**, utilizando algoritmos de clasificación tradicionales y redes neuronales.
- **Evaluar objetivamente los modelos**, usando métricas como accuracy, precisión, recall y F1-score.
- **Asignar niveles de estrés de forma interpretativa**, dividiendo las predicciones en cuatro rangos: demasiado relajado, estrés bajo, moderado y alto.
- **Representar los resultados de manera visual**, tanto en gráficos como en informes generados mediante Power BI.
- **Diseñar una arquitectura escalable en la nube (Google Cloud)** que permita alojar el sistema, automatizar tareas o facilitar su despliegue en entornos reales.

5. METODOLOGÍA

Esta sección describe el flujo completo seguido para desarrollar el sistema de predicción del nivel de estrés, desde la adquisición de los datos hasta la implementación y evaluación de los modelos.

5.1. DESCRIPCION DE LOS DATASET DE SWELL-KW

El proyecto se basa en el uso del conjunto de datos SWELL-KW (SWELL Knowledge Work), desarrollado para investigar el estrés en el contexto del trabajo de conocimiento. Fue recopilado mediante un experimento controlado con 25 participantes, quienes realizaron tareas habituales de oficina como escribir informes, preparar presentaciones, leer correos electrónicos y buscar información.

Durante estas tareas se manipularon dos factores clave para inducir estrés:

- Interrupciones frecuentes por correo electrónico
- Presión de tiempo

El dataset es multimodal y recoge datos en diferentes dimensiones:

- A. Interacción informática (Computer Logging): eventos de teclado, ratón y ventanas activas, registrados en formato *uLog*.
- B. Expresiones faciales: grabadas en vídeo y procesadas con *FaceReader* para extraer emociones, atención, valencia, etc.
- C. Posturas corporales: captadas con un sensor *Kinect 3D*, analizando la posición de diversas partes del cuerpo.
- D. Señales fisiológicas: registradas con sensores *Mobi*, incluyendo frecuencia cardíaca (HR), variabilidad del ritmo cardíaco (HRV) y conductancia de la piel (SCL). Estas variables están disponibles en el archivo consolidado D - Physiology features (HR_HRV_SCL - final).csv.

Además de los datos objetivos, el estudio incluyó cuestionarios subjetivos validados para valorar la experiencia de los participantes en cuanto a:

- Carga de trabajo (*NASA-TLX*)
- Esfuerzo mental (*RSME*)
- Emoción (*SAM*)
- Estrés percibido

Todos los registros fueron organizados por condiciones experimentales (bloques 1, 2 y 3). En este proyecto, se llevó a cabo un preprocesamiento adicional para estructurar y transformar los datos, facilitando su análisis conjunto y la extracción de características relevantes a partir de diferentes tipos de información recogida.

5.2. PROCESO DE ETL Y LIMPIEZA DE DATOS

Se aplicó un pipeline común de procesamiento y limpieza de datos para los cuatro subconjuntos multimodales (interacción informática, expresiones faciales, postura corporal y señales fisiológicas). Las principales tareas realizadas fueron:

- Conversión de formatos heterogéneos: integración de datos provenientes de distintos formatos como .csv, .ods o .xlsx, adaptando su estructura para un tratamiento homogéneo.
- Revisión de metadatos: se aseguraron columnas clave como el identificador del participante, el bloque experimental o las marcas de tiempo, unificando la nomenclatura y garantizando la trazabilidad.
- Limpieza de valores nulos o extremos: detección de datos faltantes o anómalos, aplicando técnicas de imputación o eliminación según el caso.
- Normalización de variables numéricas: escalado de características para homogeneizar rangos y facilitar el aprendizaje de los modelos.
- Unificación de criterios entre datasets: se mantuvo una estructura coherente y alineada en todos los subconjuntos, facilitando su posterior combinación y análisis conjunto.

5.3. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Una vez completada la fase de limpieza, se realizó un análisis exploratorio sobre los distintos conjuntos de datos con el objetivo de comprender mejor su distribución, comportamiento y relaciones internas. Este proceso incluyó:

- Cálculo de estadísticas descriptivas para identificar tendencias generales y rangos de valores.
- Visualización de distribuciones de variables clave mediante histogramas, gráficos de densidad y diagramas de dispersión.
- Análisis de correlaciones entre variables numéricas para detectar redundancias o relaciones relevantes.
- Detección de valores atípicos y posibles anomalías que pudieran afectar al rendimiento de los modelos.
- Comparación entre condiciones experimentales, analizando cómo varían determinadas métricas según el nivel de estrés inducido.

Este análisis permitió obtener una visión inicial del comportamiento de los datos y sirvió como base para la selección de características y el diseño de los modelos predictivos.

5.4. PREPROCESAMIENTO DE DATOS

Tras la limpieza inicial y el análisis exploratorio, se aplicaron transformaciones adicionales para adaptar los datos a los requisitos de los modelos de aprendizaje automático. Este preprocesamiento incluyó:

- Conversión de variables categóricas en formato numérico mediante técnicas de codificación (por ejemplo, label encoding).
- Revisión de la tipología de variables y conversión de tipos de datos donde fue necesario.
- Escalado de variables numéricas, utilizando técnicas de normalización o estandarización para garantizar una distribución adecuada para los algoritmos de clasificación.
- Balanceo de clases, aplicando técnicas como ajuste de pesos o sobremuestreo cuando fue necesario para mejorar la equidad del modelo.
- División del dataset en conjuntos de entrenamiento y prueba (train-test split) para asegurar una evaluación imparcial del rendimiento del modelo.
- Consolidación del dataset final, combinando las distintas fuentes ya preprocesadas en una única estructura coherente y lista para su uso en el modelado.

Estas transformaciones garantizaron la calidad, consistencia y compatibilidad del conjunto de datos con los algoritmos utilizados posteriormente en el proceso de modelado.

5.5. EXTRACCIÓN Y SELECCIÓN DE CARACTERÍSTICAS

Dado el carácter multimodal del dataset y la gran cantidad de variables disponibles tras el preprocesamiento, fue necesario aplicar técnicas de extracción y selección de características para reducir la dimensionalidad y mejorar la eficiencia de los modelos.

Las acciones realizadas incluyeron:

- **Extracción de características estadísticas** como medias, desviaciones estándar y máximos/mínimos en ventanas temporales, especialmente en señales fisiológicas y datos de expresión/postura.
- **Unificación y combinación de variables** provenientes de distintas fuentes (fisiología, rostro, postura e interacción) en un único dataset estructurado.
- **Análisis de correlación** para eliminar variables redundantes o altamente correlacionadas entre sí.
- **Importancia de características** mediante modelos como Random Forest y XGBoost, lo que permitió identificar las variables más relevantes para la predicción del estrés.
- **Selección manual basada en interpretación y contexto**, descartando variables poco informativas, duplicadas o con comportamiento errático.
- **Reducción del número total de variables** manteniendo aquellas con mayor peso predictivo, mejorando así el rendimiento y la interpretabilidad del modelo.

Este proceso permitió construir una base de datos compacta, optimizada y representativa, fundamental para la fase de modelado posterior.

6. MODELADO Y EVALUACIÓN

Una vez preparado el dataset final, se implementaron diferentes modelos de clasificación para predecir el nivel de estrés a partir de datos multimodales. El objetivo fue comparar su rendimiento y seleccionar la opción más adecuada en función de las métricas obtenidas.

6.1. MODELOS IMPLEMENTADOS

Se probaron diversos algoritmos de clasificación, tanto tradicionales como basados en redes neuronales, con el fin de valorar su eficacia ante un problema con múltiples fuentes de datos. Los modelos utilizados fueron:

- **Regresión Logística (LogReg):** modelo base lineal, útil para establecer un punto de comparación.
- **Random Forest:** modelo de ensamblado basado en árboles, eficaz para detectar relaciones no lineales y manejar variables mixtas.
- **XGBoost:** algoritmo de gradient boosting optimizado, robusto frente a overfitting y muy competitivo en tareas de clasificación estructurada.
- **Red Neuronal LSTM:** red neuronal secuencial utilizada para capturar dependencias temporales o patrones más complejos en los datos, especialmente relevante en el contexto fisiológico y emocional.

Cada modelo fue entrenado con los mismos datos, aplicando ajustes específicos de hiperparámetros según el caso.

6.2. METRICAS DE EVALUACION

Para valorar el comportamiento y precisión de los modelos implementados en el proyecto, se utilizaron métricas estándar tanto para problemas de clasificación binaria como para aquellos enfocados desde una perspectiva regresiva.

Métricas para modelos de clasificación:

- **Accuracy:** mide la proporción de predicciones correctas sobre el total, útil como referencia general del rendimiento.
- **Precisión y Recall:** permiten analizar el equilibrio entre falsos positivos y falsos negativos, lo que resulta clave en escenarios donde el coste del error no es uniforme.
- **F1-Score:** representa la media armónica entre precisión y recall, especialmente útil cuando existe cierto desbalance entre clases.
- **Matriz de confusión:** proporciona una representación visual detallada de los aciertos y errores por clase, permitiendo interpretar el tipo de fallo cometido.
- **Curva ROC y AUC** (cuando ha sido aplicable): utilizadas para evaluar la capacidad discriminativa de los modelos en distintas condiciones de umbral de decisión.

Métricas para modelos con salida continua:

- **R² (Coeficiente de determinación):** indica la proporción de la varianza total explicada por el modelo. Cuanto más cercano a 1, mejor el ajuste.

- **MAE (Mean Absolute Error)**: calcula el error promedio entre las predicciones y los valores reales, ofreciendo una medida interpretable del margen medio de error.
- **MSE (Mean Squared Error)**: penaliza los errores grandes al elevarlos al cuadrado, útil para comparar distintos modelos con diferentes niveles de precisión.
- **RMSE (Root Mean Squared Error)**: ofrece una versión ajustada del MSE en la misma escala que la variable de salida, facilitando su interpretación práctica.

Estas métricas han permitido realizar una evaluación completa del rendimiento de los distintos modelos implementados, comparar sus resultados de forma objetiva y seleccionar aquellos más adecuados para la tarea de predicción del nivel de estrés.

6.3. RESULTADOS OBTENIDOS

Los resultados evidenciaron que todos los modelos ofrecieron un rendimiento aceptable en la clasificación binaria del nivel de estrés, destacando especialmente XGBoost y la red neuronal LSTM, que lograron las mejores puntuaciones globales. En concreto:

XGBoost mostró un excelente equilibrio entre precisión y generalización, con gran estabilidad frente al ruido y rapidez en el entrenamiento.

LSTM: aunque más compleja, fue capaz de detectar patrones temporales en las señales multimodales, con una alta capacidad predictiva, especialmente en situaciones extremas (estrés alto o relajación completa).

CatBoost: ofreció un rendimiento sólido, destacando por su facilidad para manejar variables categóricas y su comportamiento estable incluso sin un ajuste exhaustivo de hiperparámetros.

Random Forest: resultó robusto y fácil de interpretar, con buenos resultados y menor sobreajuste respecto a modelos más simples.

Decision Tree: aunque más limitado en rendimiento, sirvió como modelo base interpretativo para entender la lógica de clasificación y visualizar reglas de decisión. Regresión Logística proporcionó una referencia inicial efectiva, estableciendo una línea base sobre la que comparar el resto de modelos.

Además, todos los modelos permitieron estimar el nivel de estrés no solo como un valor continuo o numérico, sino también como una categoría cualitativa (estrés alto o bajo), lo que facilitó su posterior visualización y análisis en Power BI.

7. DESPLIEGUE DEL SISTEMA

Para facilitar el uso del modelo de predicción fuera del entorno de desarrollo y permitir su integración con otras aplicaciones o servicios, se desarrolló una API funcional y se planteó una arquitectura escalable basada en servicios en la nube.

7.1. FASTAPI

Se desarrolló una API REST con FastAPI para permitir el uso del modelo de predicción de estrés de forma práctica, escalable y accesible desde cualquier interfaz externa. Esta implementación simula el funcionamiento de un servicio en producción, listo para integrarse en entornos reales como plataformas de recursos humanos o herramientas de monitorización de bienestar.

Características principales:

- o Subida de archivos tanto videos y modelos de aprendizaje automático a un bucket de CGP. Se usas servicios servicces_GCP.py
- o Carga de modelos subidos, como son XGboost o LSTM, carga de video y selección de tipo de modelo para después predecir.
- o El video se procesa con funciones, aplicando la librería MediaPipe, enconcreto, Pose y Mesh. Se sacan medidas excatamente iguales a las descritas en el experimento SWELL
- o Procesamiento automático de los datos entrantes: adaptación del input al formato esperado por el modelo (orden de columnas, tipos de datos) usando funciones personalizadas
- o Predicción del nivel de estrés y generación de respuesta estructurada con el resultado. • Los resultados se guardan en una base da datos alojada en un bucket de GCP si el usuario así lo desea. Diseño y extensibilidad: La API fue diseñada para facilitar su escalabilidad futura. Su arquitectura admite:
- o La integración de nuevos modelos mediante simples cambios en el archivo de carga.
 - La posible conexión con frontends o dashboards (por ejemplo, Power BI, Streamlit o plataformas web).
- o El despliegue en servicios en la nube como Cloud Run o Heroku, gracias a su estructura ligera.
- o Esta diseñada para poder hacer una adaptación a Spark cuando la la app pase a producción.

Esta solución convierte el modelo de predicción en un servicio consumible por terceros, abriendo la puerta a su integración en productos tecnológicos orientados al bienestar laboral, el análisis emocional o la inteligencia organizacional.

7.2. ARQUITECTURA DEL SISTEMA EN GOOGLE CLOUD PLATFORM (GCP)

Para garantizar un entorno de trabajo colaborativo, escalable y accesible desde distintas ubicaciones geográficas, el proyecto se desplegó sobre Google Cloud Platform (GCP), bajo el nombre **PFB KeepCoding**.

Arquitectura básica:

Se configuró una instancia principal (**sheet-pfb14kc**) en la región europe-southwest1-b, con las siguientes características:

- PostgreSQL 16 como sistema operativo base.
- 4 CPUs virtuales y 16 GB de RAM.
- 100 GB de almacenamiento SSD.
- Conexión a IP pública.
- Copias de seguridad diarias programadas entre las 00:00 y 04:00 h.

El entorno se mantuvo activo de forma continua para facilitar la colaboración entre miembros del equipo ubicados en distintas zonas horarias (incluyendo Sudamérica).

Cloud Storage

Se organizaron varios buckets en función de las diferentes acciones a realizar en las fases del proyecto:

- bucket-pfb_keepcoding1: datasets tratados.
- bucket-pfb_keepcoding2: modelos entrenados (XGBoost y FastAPI).
- bucket-pfb_keepcoding3: modelos experimentales (LSTM para MLflow).
- bucket-pfb_keepcoding4: pruebas generales.

Cloud Run y GitHub

El preprocesado y versionado de los datos se gestionó desde GitHub, contemplando su futura integración con Cloud Run, aunque finalmente no se utilizó activamente esta funcionalidad.

IAM y gestión de accesos

Dada la naturaleza distribuida del equipo, se configuraron credenciales individuales para enlazar los buckets y herramientas utilizadas:

- Fernando: acceso vinculado a FastAPI.
- Pablo: gestión de modelos vía MLflow.
- Gabriela: integración con herramientas de Business Intelligence (BI).

Costes y optimización

Inicialmente se utilizó una máquina de mayor capacidad, pero al detectarse infrautilización se optimizó su configuración, reduciendo significativamente el coste diario del servicio.

8. VISUALIZACIÓN DE RESULTADOS EN POWER BI

Para facilitar la interpretación de los resultados obtenidos por los modelos y presentar la información de forma clara e interactiva, se desarrollaron distintos dashboards en Power BI. Estos paneles permiten analizar tanto los datos recogidos como las predicciones generadas, favoreciendo una comprensión accesible y profunda del fenómeno del estrés. A continuación, se describe el contenido de cada pestaña del informe:

8.1. ANÁLISIS GENERAL POR CONDICIÓN E INDICADORES

Esta sección proporciona una visión general del nivel de estrés de los participantes, desglosando los porcentajes de personas con estrés alto, moderado, bajo o sin estrés. Incluye gráficos comparativos por condición experimental (T, I, N) sobre:

- Esfuerzo y frustración.
- Estrés medio por participante.
- Relación entre esfuerzo mental y conductancia de la piel (SCL).
- Desempeño medio según condición.

Se incorporan segmentadores interactivos para filtrar por persona, condición o momento del día.

8.2. ESTADO EMOCIONAL POR CATEGORÍAS DE ESTRÉS

Esta página muestra el promedio de emociones básicas (ira, disgusto, felicidad, tristeza, miedo y sorpresa) en función del nivel de estrés. Permite explorar cómo varían las emociones percibidas entre individuos estresados y no estresados, proporcionando insights emocionales valiosos para el análisis de bienestar.

8.3. COMPARATIVA DE MODELOS PREDICTIVOS.

En esta sección se evalúa el rendimiento de distintos modelos de machine learning aplicados a la predicción del estrés:

- Árbol de Decisión
- Regresión Logística
- Random Forest
- XGBoost
- Catboost
- LSTM

Se comparan métricas como R-cuadrado, MAE, MSE, RMSE y Loss, representadas mediante un gráfico de barras agrupadas que facilita la comparación visual.

8.4. CONCLUSIONES DEL ANÁLISIS:

Esta pestaña recoge de forma resumida las principales conclusiones extraídas del estudio, clasificadas por:

- Nivel de estrés
- Condición experimental
- Estado de ánimo asociado
- Momento del día

Se concluye que el estrés tiende a ser mayor en condiciones de interrupción o presión de tiempo, y que existe una relación emocional significativa entre el estrés alto y sentimientos de tristeza. Además, se observa que los niveles de estrés son mayores por la tarde/noche que por la mañana.

9. CONCLUSIONES Y TRABAJO FUTURO

Durante el desarrollo del proyecto han surgido diversas líneas de mejora y ampliación, que se plantean como continuación natural:

- Captura de datos en tiempo real, integrando directamente cámaras o sensores conectados.
- Despliegue completo del sistema en la nube, con automatización de predicciones desde una interfaz web o móvil.
- Ampliación del conjunto de datos, incluyendo más participantes y situaciones para mejorar la generalización de los modelos.
- Refinamiento de modelos con técnicas avanzadas, como redes neuronales convolucionales aplicadas a vídeo o señales fisiológicas crudas.
- Análisis más profundo de errores y casos mal clasificados, para detectar patrones ocultos o sesgos.

Estas mejoras permitirían escalar el sistema a contextos reales y sentar las bases para su explotación comercial o investigación futura.

10. BIBLIOGRAFÍA O REFERENCIAS

- S. G. Veltkamp, B. Koldijk, M. A. Neerincx. "The SWELL Knowledge Work Dataset for Stress and User Modeling Research." Proceedings of the 16th International Conference on Multimodal Interaction (ICMI '14). 2014.
- <https://dl.acm.org/doi/10.1145/2663204.2663272>
- Koldijk, S., Neerincx, M. A., & Kraaij, W. (2016). "Detecting Work Stress in Offices by Combining Physiological, Behavioral and Contextual Features." IEEE Transactions on Affective Computing, 9(2), 227–239.
- <https://doi.org/10.1109/TAFFC.2016.2616445>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). "Scikit-learn: Machine Learning in Python." Journal of Machine Learning Research, 12, 2825–2830.
- Chollet, F. et al. (2015). Keras: Deep Learning for Humans. <https://keras.io>
- Lundberg, S. M., & Lee, S. I. (2017). "A Unified Approach to Interpreting Model Predictions." Advances in Neural Information Processing Systems 30 (NeurIPS 2017).
- https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html
- Microsoft Power BI. <https://powerbi.microsoft.com/>
- Google Cloud Platform – Documentación oficial. <https://cloud.google.com/docs>
- FastAPI – Documentación oficial. <https://fastapi.tiangolo.com/>

11. ANEXOS

En esta sección se recogen los materiales complementarios desarrollados durante el proyecto, que sirven de soporte para comprender la implementación técnica y los resultados alcanzados.

11.1. NOTEBOOKS DE ANALISIS Y PROCESAMIENTO

- Subset_A_analysys_pipe_revisado_y_completo.ipynb: Análisis de interacciones con el ordenador.
- Subset_B_Analysys.ipynb: Análisis de expresiones faciales.
- Subset_C_analisis.ipynb: Análisis de postura corporal (Kinect).
- Subset_D.ipynb: Procesamiento de señales fisiológicas.
- preprocess_data.ipynb: Consolidación y preprocesamiento conjunto de los datos.
- modelos_comparativa.ipynb: Entrenamiento y evaluación de modelos.
- api_fastapi.ipynb: Implementación del endpoint de predicción mediante FastAPI.

11.2. VISUALIZACIONES EN POWER BI

- Capturas de dashboards interactivos con filtros por participante, modelo y condición experimental.
- Gráficos temporales del nivel de estrés por minuto.
- Comparativa de métricas de evaluación por modelo.

11.3. ENLACES COMPLEMENTARIOS

- Repositorio de código (GitHub): https://github.com/Pablo-Sapiens/Proyecto_final
- URL pública de la API (si está desplegada)